

머신 러닝·딥러닝에 필요한 수학 기초 with 파이썬

Matrix and Vector Calculation,
Numpy

행렬과 벡터의 연산, Numpy

조준우

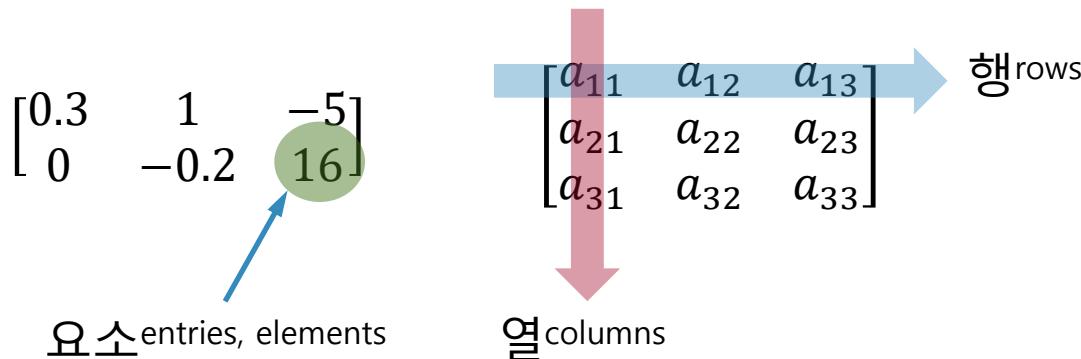
metamath@gmail.com

학습 개요

- 선형대수가 가장 중요?
 - 딥러닝: 한 벡터 공간을 다른 벡터 공간으로 매핑하기 위한 단순하고 연속된 기하학적 변환을 연결한 것(Chollet, François, Deep learning with python)
- 행렬과 벡터
 - 기본 정의
 - 연산
 - 행렬곱, 행렬-벡터곱의 해석
- 행렬을 이용한 데이터의 표현
 - 테이블형 데이터
 - 이미지
 - 문서
- 벡터화 코딩 실습

행렬 Matrix

- 사각 괄호로 둘러 쌓인 숫자들의 배열(Rectangular array of numbers written between square brackets)



행렬 Matrix

- 볼드 대문자 표시
- 행렬의 차원(크기) : 행 개수 × 열 개수

$$\mathbf{A} = [a_{jk}] = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

- 보기의 경우 $m \times n$ 행렬
- 요소의 첫 번째 인덱스가 행 번호, 두 번째 인덱스가 열 번호

행렬 Matrix

- 아래 행렬에서
- 행렬의 크기 2×3
- $a_{12} = 1$
- $a_{22} = -0.2$
- $a_{23} = 16$

$$\mathbf{A} = \begin{bmatrix} 0.3 & 1 & -5 \\ 0 & -0.2 & 16 \end{bmatrix}$$

행렬의 덧셈과 스칼라 곱셈

- 두 행렬 A, B 의 크기가 같을 때 같은 위치의 요소의 덧셈

$$A = \begin{bmatrix} 3 & 1 \\ 10 & 12 \end{bmatrix} \quad B = \begin{bmatrix} 5 & 1 \\ 3 & -2 \end{bmatrix} \quad A + B = \begin{bmatrix} 8 & 2 \\ 13 & 10 \end{bmatrix}$$

- 크기가 다르면 덧셈 불가능
- 행렬에 대한 스칼라 곱은 각 요소에 스칼라를 곱하는 것

행렬 덧셈, 스칼라 곱 예

$$\begin{bmatrix} 8 & 2 \\ 16 & 10 \end{bmatrix} \times \frac{1}{2} + 3 \times \begin{bmatrix} 1 & 1 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 4 & 1 \\ 8 & 5 \end{bmatrix} + \begin{bmatrix} 3 & 3 \\ 9 & 2 \end{bmatrix} = \begin{bmatrix} 7 & 4 \\ 17 & 17 \end{bmatrix}$$

```
A = np.asarray([8,2,16,10]).reshape(2,2)
```

```
B = np.asarray([1,1,3,4]).reshape(2,2)
```

```
print(A*(1/2) + 3*B)
```

```
[[ 7.  4.]  
 [17. 17.]]
```

행렬-행렬의 곱셈

- 행과 열의 요소를 곱해서 더함.

$$\begin{array}{c} \text{A} \\ \times \\ \text{B} \end{array} = \text{C}$$

$\begin{matrix} m \times n & \text{matrix} \\ n \times p & \text{matrix} \\ m \times p & \text{matrix} \end{matrix}$

The diagram illustrates the multiplication of two matrices, A and B, to produce matrix C. Matrix A is shown as a blue arrow pointing right, labeled 'A'. Matrix B is shown as a red arrow pointing down, labeled 'B'. The resulting matrix C is shown as a green circle, labeled 'C'. Below the arrows, their dimensions are indicated: $m \times n$ matrix, $n \times p$ matrix, and $m \times p$ matrix.

$$\text{circle} = a_{11}b_{11} + a_{12}b_{21} + \cdots + a_{1n}b_{n1}$$

행렬-행렬의 곱셈

- 모든 행과 모든 열에 대해서 반복 계산

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \\ a_{41} & a_{42} \end{bmatrix}$$
$$B = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \end{bmatrix}$$
$$C = \begin{bmatrix} c_{11} & c_{12} & c_{13} \\ c_{21} & c_{22} & c_{23} \\ c_{31} & c_{32} & c_{33} \\ c_{41} & c_{42} & c_{43} \end{bmatrix}$$

```
A = np.asarray([1, 2, 23, 43, 56, 32, 41, 55]).reshape(4,2)
B = np.asarray([11, 12, 13, 21, 22, 23]).reshape(2,3)
C = np.dot(A,B)
print(C)
```

```
[[ 53  56  59]
 [1156 1222 1288]
 [1288 1376 1464]
 [1606 1702 1798]]
```

#반대로 곱할 수 있을까?

행렬의 전치Transpose

- 주어진 행렬의 행을 열로, 열을 행으로 이동
- A^T 로 표시

- $(AB)^T = B^TA^T$

$$A = \begin{bmatrix} 5 & -8 & 1 \\ 4 & 0 & 3 \end{bmatrix} \quad A^T = \begin{bmatrix} 5 & 4 \\ -8 & 0 \\ 1 & 3 \end{bmatrix}$$

```
A = np.asarray([5, -8, 1, 4, 0, 3]).reshape(2,3)
print(A.T)
```

```
[[ 5 4]
 [-8 0]
 [ 1 3]]
```

```
B = np.asarray([3, 1, 0, 1, 2, 8]).reshape(3,2)
print(np.dot(A,B).T)
```

```
[[17 18]
 [ 5 28]]
```

```
print(np.dot(B.T, A.T))
```

특별한 행렬

- **단위행렬** unit, identity matrix

- 대각 성분이 모두 1인 $n \times n$ 정사각 행렬, I_n, I
 - $AI = IA = A$

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- **대각행렬** diagonal matrix

- 대각 성분만 0이 아닌 성분을 가진 $n \times n$ 정사각 행렬

$$D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -3 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- **대칭행렬** symmetric matrix

- 정사각 행렬에 대해서 $S^T = S$, 따라서 $s_{kj} = s_{jk}$ 인 행렬

$$S = \begin{bmatrix} 10 & 20 & 100 \\ 20 & 10 & 120 \\ 100 & 120 & 20 \end{bmatrix}$$

역행렬 Inverse

- $n \times n$ 행렬 A 의 역행렬은 A^{-1} 로 표시하며 다음을 만족

$$AA^{-1} = A^{-1}A = I$$

- 역행렬을 가지면 A 는 정칙행렬 nonsingular matrix, 역행렬이 없으면 특이행렬 singular matrix
- 1차 연립 방정식의 해

$$\begin{aligned} 2x_1 + 1x_2 &= 3 \\ -6x_1 + 3x_2 &= -27 \end{aligned} \quad \rightarrow \quad \begin{bmatrix} 2 & 1 \\ -6 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ -27 \end{bmatrix}$$

$$\begin{bmatrix} 2 & 1 \\ -6 & 3 \end{bmatrix}^{-1} \begin{bmatrix} 2 & 1 \\ -6 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ -6 & 3 \end{bmatrix}^{-1} \begin{bmatrix} 3 \\ -27 \end{bmatrix} \quad \rightarrow \quad \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ -6 & 3 \end{bmatrix}^{-1} \begin{bmatrix} 3 \\ -27 \end{bmatrix}$$

벡터 Vector

- 행렬 관점에서 행이나 열을 하나만 가진 행렬
- 행렬의 크기가 $n \times 1$ 인 행렬
- 숫자 여러 개의 모임
- 행 벡터 또는 열 벡터라 하며 대부분 **별도의 언급이 없으면 벡터는 열 벡터**
- 볼드 소문자 표시
- 벡터의 차원 : 요소 개수, 보기의 경우 n 차원 벡터

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

벡터 Vector

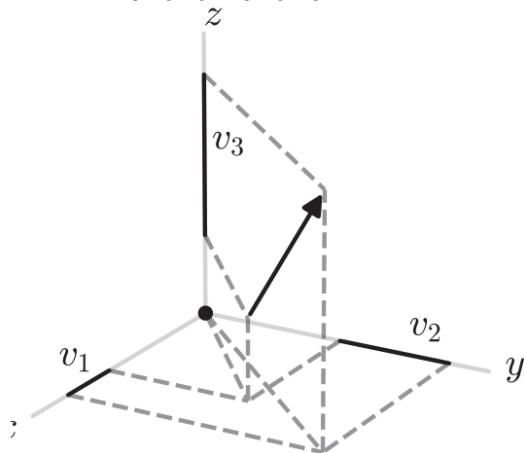
- 아래 벡터에서 벡터의 차원 4
- $v_1 = 23$
- $v_2 = 13$
- $v_4 = 100$

$$\mathbf{v} = \begin{bmatrix} 23 \\ 13 \\ 8 \\ 100 \end{bmatrix}$$

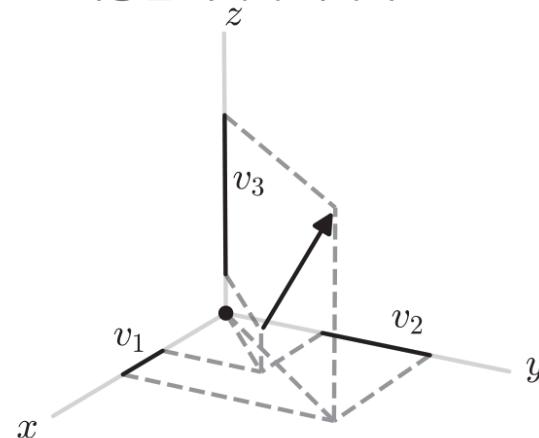
벡터Vector: 숫자 여러 개 모임?

- 3차원 공간의 화살표는 방향과 크기를 가짐
- 3차원 공간의 화살표: 숫자 세 개로 표현 가능

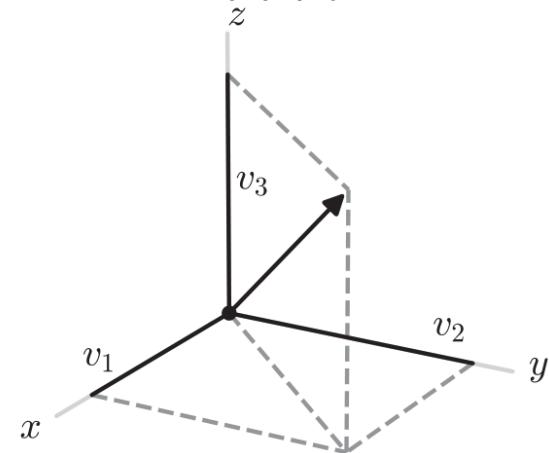
벡터와 벡터의 요소



이동된 벡터와 벡터의 요소

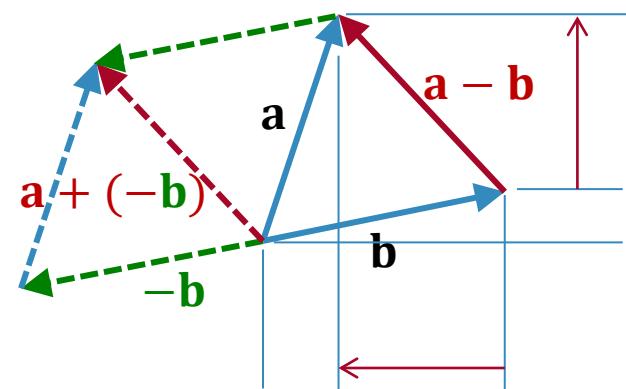
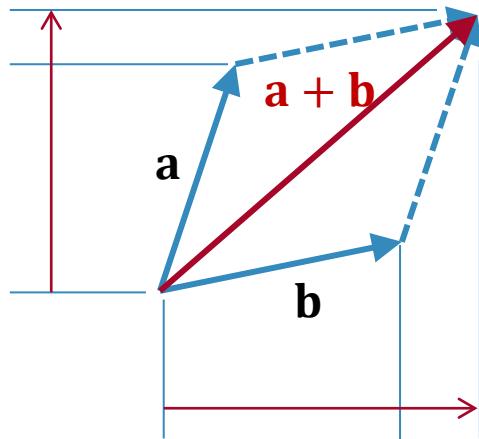


위치벡터



벡터의 덧셈, 뺄셈

- 벡터의 덧셈, 뺄셈은 요소끼리 덧셈, 뺄셈
- 덧셈 : 두 벡터가 이루는 평행 사변형으로 계산
- 뺄셈 : $a - b = a + (-b)$ 로 두고 덧셈과 동일하게 계산

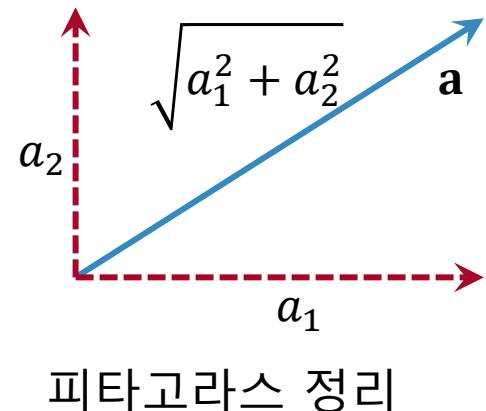


벡터의 크기(놈, 노름)Norm

- 2차원 벡터의 길이(크기) $|\mathbf{a}| = \sqrt{a_1^2 + a_2^2}$

- 노름 길이에 대한 일반적인 정의

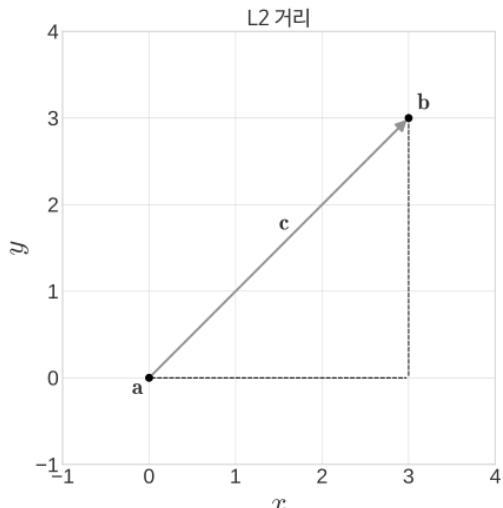
$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$



벡터의 크기(높, 노름)Norm

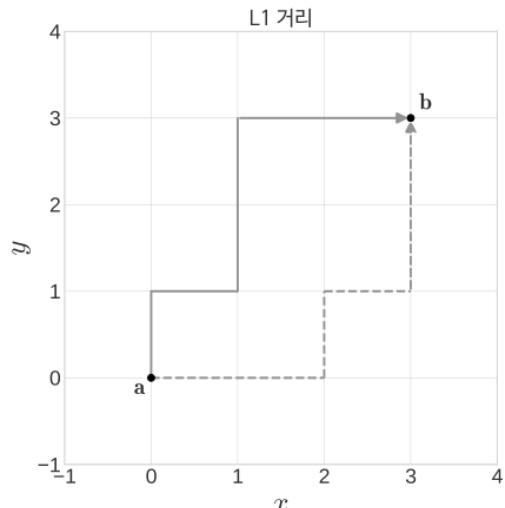
- L1 노름

$$\|\mathbf{x}\|_1 = \left(\sum_{i=1}^n |x_i| \right)$$



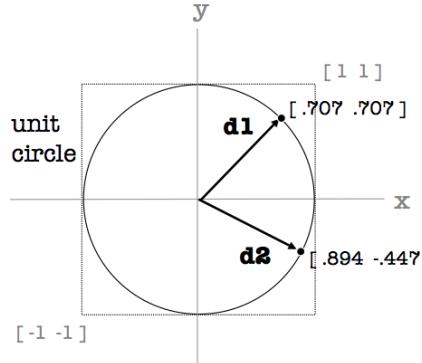
- L2 노름

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{\frac{1}{2}} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$



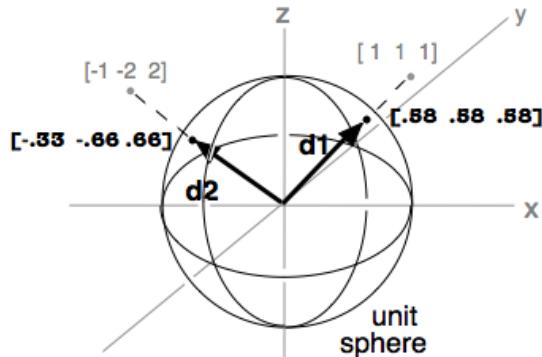
단위 벡터 Unit vector

- 크기가 1인 벡터
- 벡터를 벡터의 크기로 나눔



$$\frac{(1 \ 1)^T}{\sqrt{2}} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix}$$

$$\hat{\mathbf{u}} = \frac{\mathbf{u}}{|\mathbf{u}|}$$

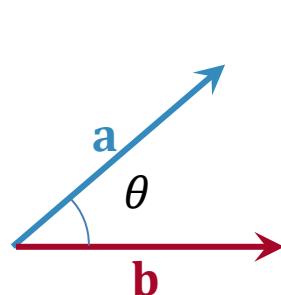


$$\frac{(-1 \ -2 \ 2)^T}{\sqrt{9}} = \begin{bmatrix} -\frac{1}{3} \\ -\frac{2}{3} \\ \frac{2}{3} \end{bmatrix}$$

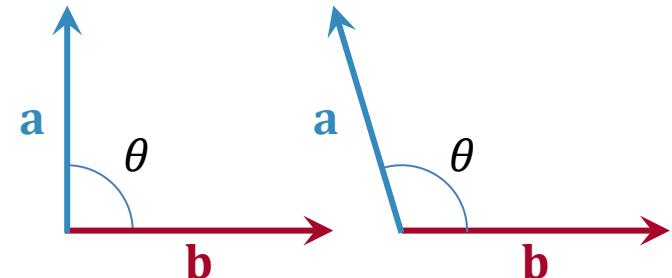
벡터-벡터의 곱셈

- 행과 열에 대해서 한번 계산
- 이런 연산을 벡터의 내적^{inner product}이라고도 함

$$\mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$
$$\mathbf{a}^T = \begin{bmatrix} a_1 & a_2 \end{bmatrix} \xrightarrow{\text{arrow}} [c_1]$$



$$\mathbf{a} \cdot \mathbf{b} > 0$$



$$\mathbf{a} \cdot \mathbf{b} = 0$$

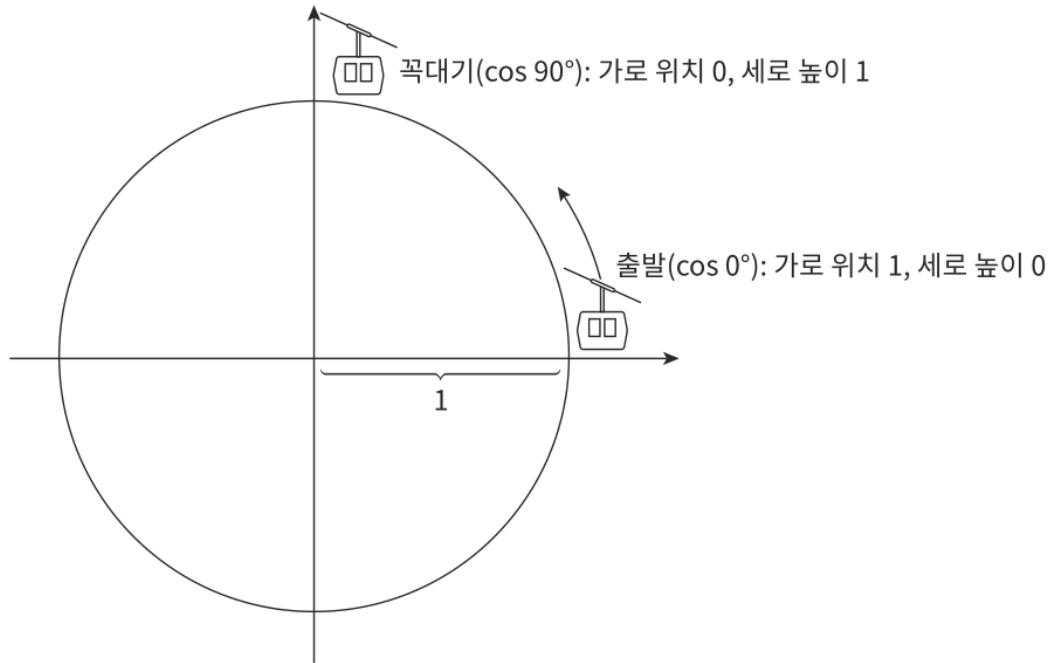
Orthogonality

$$\mathbf{a} \cdot \mathbf{b} < 0$$

$$\mathbf{a}^T \mathbf{b} = \mathbf{a} \cdot \mathbf{b} = |\mathbf{a}| |\mathbf{b}| \cos \theta$$

\cos : 가로함수, \sin : 세로함수

- 대관람차의 위치를 가로, 세로로 나타낼 때
- 각도에 따른 가로 위치는 \cos 함수, 세로 높이는 \sin 함수



행렬을 이용한 데이터 표현: 테이블형데이터

- 신체 특징 데이터: 키, 몸무게, 혈압, ...
- 한 명 데이터를 벡터로 표시: $\mathbf{x} = (\text{키}, \text{몸무게}, \text{혈압}, \dots)^T$
- 개별 데이터를 행 벡터로 저장
- 데이터 행렬 $\mathbf{X} : (N, D)$, N: 데이터 개수, D: 데이터 차원

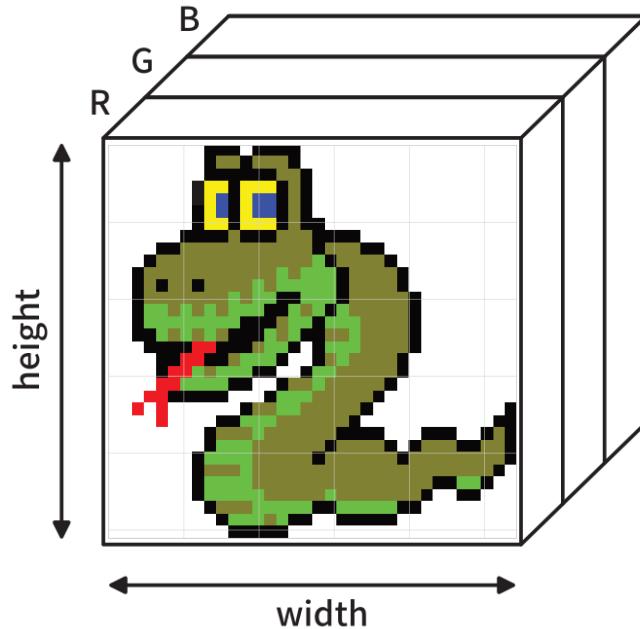
	키	몸무게	혈압	...
\mathbf{x}_1	170	64	90/100	...
\mathbf{x}_2	172	70	120/130	...
...
\mathbf{x}_N	182	82	100/120	...

개별 데이터

키 벡터

행렬을 이용한 데이터 표현: 이미지

- Channel first: (C, H, W), Channel last: (H, W, C)



행렬을 이용한 데이터 표현: 문서

```
docs = [  
    'This is the first document', [[9, 4, 7, 3, 2], [9, 4, 7, 6, 2], [1, 7, 8, 5], [4, 9, 7, 3, 2]]]  
    'This is the second document',  
    'And the third one',  
    'Is this the first document']  
  
V = ['<NULL>', 'and',  
     'document', 'first', 'is',  
     'one', 'second', 'the',  
     'third', 'this']  
  
[  
    [9] → [0,0,0,0,0,0,0,0,1]  
    [4] → [0,0,0,0,1,0,0,0,0]  
    [7] → [0,0,0,0,0,0,1,0,0]  
    [3] → [0,0,0,1,0,0,0,0,0]  
    [2] → [0,0,1,0,0,0,0,0,0]  
]
```

인덱스 Index

- 행렬, 벡터의 요소를 지정하기 위해 아래첨자로 사용하는 숫자
- 0부터 시작하는 방식과 1부터 시작하는 방식이 있음
- 수학** : 1부터 시작
- 컴퓨터 공학** : 0부터 시작
- 프로그램 언어

$$\mathbf{v} = \begin{bmatrix} 23 \\ 13 \\ 8 \\ 100 \end{bmatrix} = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} v_0 \\ v_1 \\ v_2 \\ v_3 \end{bmatrix}$$

1부터 시작	0부터 시작
FORTRAN	Python
Julia	C/C++
MATLAB [©]	Java,
Octave	Javascript

Numpy

Numpy is the core library for scientific computing in Python. It provides a high-performance multidimensional array object, and tools for working with these arrays. If you are already familiar with MATLAB®, you might find this tutorial useful to get started with Numpy. – cs231n

ndarray

- numpy에서 제공하는 메인 객체인 배열
- 다차원 배열 multidimensional array로써 1차원 배열(벡터), 2차원 배열(행렬), 3차원 배열(큐브), 4차원 배열(큐브가 여러 개 모인 것) 등등 계속 차원을 늘릴 수 있음
- 생성 : 행 우선 방식으로 []로 적어주면 됨

```
import numpy as np  
# 모든 요소가 0인 어레이  
B = np.zeros(3,3)  
  
# 값을 지정하여 생성  
A = np.array([[1,2],[3,4]])  
  
# 랜덤으로 생성  
E = np.random.rand(10)  
F = np.random.rand(25).reshape(5,-1)  
G = np.random.randint(1, 11, 9).reshape(3,3)  
  
# 모든 요소가 1인 어레이  
C = np.ones(2,3)  
  
# 대각 요소만 1인 어레이  
D = np.eye(2)
```

Numpy 행렬-행렬의 곱셈

- Numpy array multiplication is not matrix multiplication

```
c = np.ones((3, 3))
```

```
C = np.matrix(c)
```

```
print("numpy array multiplication")
```

```
print(c*c)
```

```
[[1. 1. 1.]
```

```
[1. 1. 1.]
```

```
[1. 1. 1.]]
```

```
print("numpy dot function")
```

```
print(c.dot(c))
```

```
[[3. 3. 3.]
```

```
[3. 3. 3.]
```

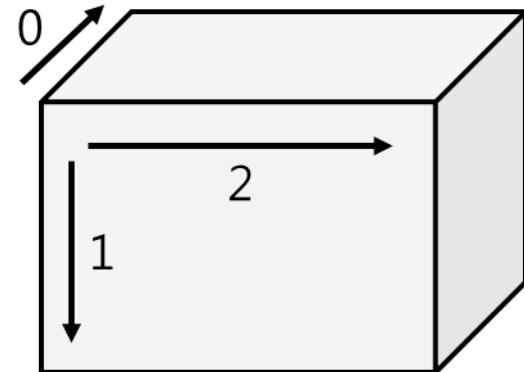
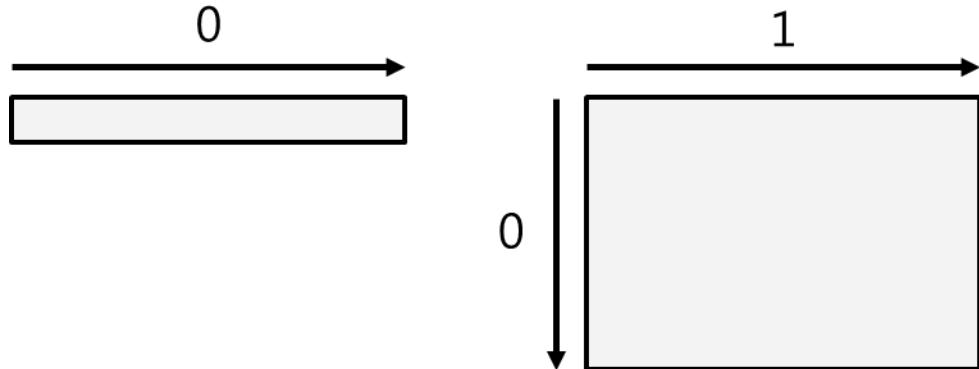
```
[3. 3. 3.]]
```

```
print("numpy matrix multiplication")
```

```
print(C*C)
```

axis

- 배열의 요소가 늘어선 방향
- 축에 번호를 붙여서 관리하는데 0부터 번호가 증가, 새롭게 생긴 axis가 0번



기본 연산

- 기본 +, -, *, / 연산자를 그냥 쓰면 되고 요소별로 연산 됨

```
A = np.array([[1,3,4], [5,3,4], [4,5,2]])  
B = np.array([[5,7,3], [2,1,1], [5,6,3]])
```

```
print(A+B)
```

```
[[ 6 10  7]  
 [ 7  4  5]  
 [ 9 11  5]]
```

```
print(A-B)
```

```
[[-4 -4  1]  
 [ 3  2  3]  
 [-1 -1 -1]]
```

```
print(A*B)
```

```
[[ 5 21 12]  
 [10  3  4]  
 [20 30  6]]
```

```
print(A/B)
```

```
[[0.2      0.4286  1.3333]  
 [2.5      3.       4.      ]  
 [0.8      0.8333  0.6667]]
```



인덱싱 indexing

- 배열의 요소에 접근하기 위해서는 인덱스를 사용

- 인덱스는 0부터 시작

- 2축 이상에 대한 인덱싱

- 3행 3열 요소 $C[2,2]$

- 1행에서 3행까지~4열에서 5열까지 : 각 인덱스 자리에서 "시작인덱스:끝인덱스" 문법 적용 $C[0:3, 3:5]$

$$C = \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 & 9 \\ 10 & 11 & 12 & 13 & 14 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 45 & 46 & 47 & 48 & 49 \end{bmatrix}$$



어레이 인덱싱array indexing

- 인덱싱할 숫자를 임의의 어레이로 전달하는 방법
- 숫자를 지정할 자리에 숫자 대신 숫자 여러 개를 포함한 어레이를 전달하면 해당되는 요소 여러 개가 한번에 추출

```
A = np.array([[1,2,3],[4,5,6]])
```

```
[[1 2 3]  
 [4 5 6]]
```

```
# [6, 2]를 만들려면?
```

```
# 그냥 하나하나 지정해서 다 모음
```

```
np.array([A[1,2], A[0,1]])
```

```
# 첫번째 리스트에 행번호
```

```
# 두번째 리스트에 열번호
```

```
A[[1,0],[2,1]]
```

- 이 성질을 잘 이용하면 지정한 특정 요소에 대해서만 연산을 수행



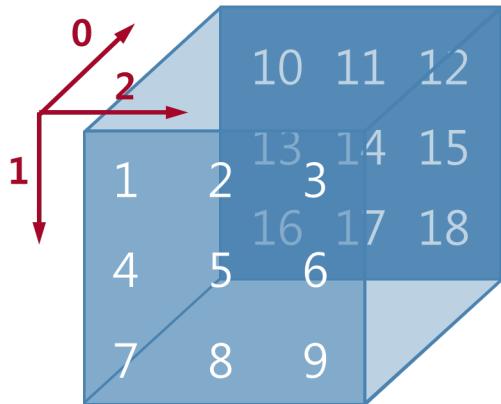
어레이 인덱싱 array indexing

- Boolean 형 어레이를 전달

```
A = np.array([[1,2,3],[4,5,6],[7,8,9]])      print(A[A > 2])  
  
A > 2  
#결과  
array([[False, False,  True],  
       [ True,  True,  True],  
       [ True,  True,  True]])  
  
#결과  
array([[ 1,  2,  3],  
       [ 4,  5,  6],  
       [ 7,  8,  9]])  
  
array([[False, False,  True],  
       [ True,  True,  True],  
       [ True,  True,  True]])  
  
array([3, 4, 5, 6, 7, 8, 9])
```

전치|transpose

- transpose(axis) : 행렬의 전치와 같은 역할, 3개축 이상에서도 같은 논리로 동작



```
B = A[0,:]  
print(B)
```

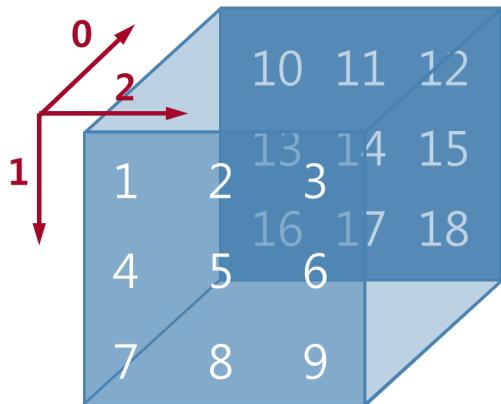
```
[[1 2 3]  
 [4 5 6]  
 [7 8 9]]
```

```
print(B.T)
```

```
[[1 4 7]  
 [2 5 8]  
 [3 6 9]]
```

전치|transpose

- transpose(axis) : 행렬의 전치와 같은 역할, 3개축 이상에서도 같은 논리로 동작



```
print(A.transpose(2, 0, 1))
```

```
[[[ 1  4  7]
 [10 13 16]]]
```

```
[[ 2  5  8]
 [11 14 17]]]
```

```
[[ 3  6  9]
 [12 15 18]]]
```

브로드캐스팅broadcasting

- Numpy에서 shape가 다른 배열 간에도 산술 연산이 가능하게 하는 매커니즘

$$\begin{array}{|c|c|c|}\hline 1 & 2 & 3 \\\hline\end{array} \times \begin{array}{|c|c|c|}\hline 2 & 2 & 2 \\\hline\end{array} = \begin{array}{|c|c|c|}\hline 2 & 4 & 6 \\\hline\end{array}$$

(3,)

(3,)

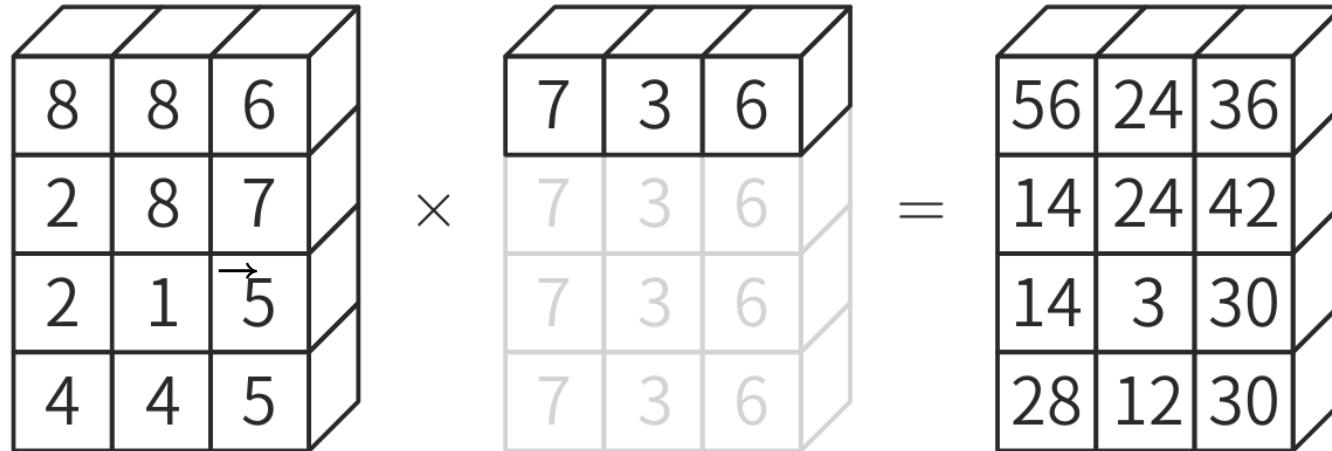
(3,)

(1,)

(3,)

(3,)

브로드캐스팅broadcasting



(4,3)

(4,3)

(4,3)

(3,)

(1,3)

(4,3)

(4,3)

브로드캐스팅broadcasting

$$\begin{array}{c} \begin{array}{|c|c|c|} \hline 9 & 9 & 9 \\ \hline 0 & 0 & 0 \\ \hline 1 & 1 & 1 \\ \hline 7 & 7 & 7 \\ \hline \end{array} & \times & \begin{array}{|c|c|c|} \hline 1 & 7 & 2 \\ \hline \end{array} & = & \begin{array}{|c|c|c|} \hline 9 & 63 & 18 \\ \hline 0 & 0 & 0 \\ \hline 1 & 7 & 2 \\ \hline 7 & 49 & 14 \\ \hline \end{array} \end{array}$$

(4,1)

(4,1)

(4,3)

(3,)

(1,3)

(4,3)

(4,3)

행렬-벡터의 곱셈

- 모든 행과 열에 대해서 반복 계산

$$\mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$
$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \\ a_{31} & a_{32} \\ a_{41} & a_{42} \end{bmatrix} \quad \mathbf{c} = \begin{bmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \end{bmatrix}$$

The diagram illustrates the calculation of the first element of the resulting vector c . It shows the second column of matrix A being multiplied by vector b to produce c_1 .

```
A = np.asarray([2, 2, 3, 8, 1, 1, 0, 1]).reshape(4,2)
b = np.asarray([3,5]).reshape(2,1)
C = np.dot(A,b)
print(C)
```

```
[[16]
 [49]
 [ 8]
 [ 5]]
```

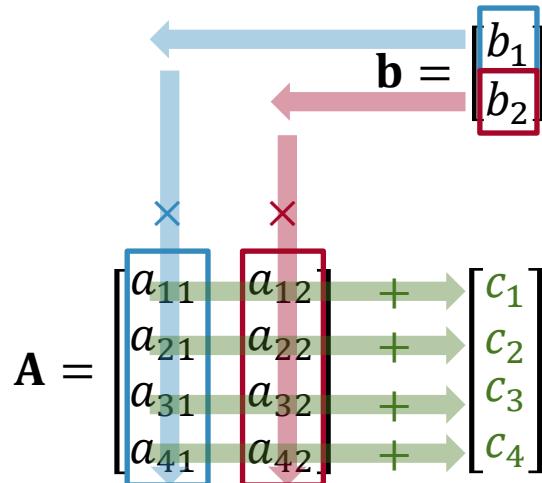
#반대로 곱할 수 있을까?

행렬-벡터의 곱셈

- 모든 열의 선형결합 linear combination
- 행렬과 행렬의 곱도 같은 작용의 반복

$$\mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

[matrix.ipynb](#)



```
A = np.asarray([2, 2, 3, 8, 1, 1, 0, 1]).reshape(4,2)  
b = np.asarray([3,5]).reshape(2,1)
```

```
A[:,0]*b[0] + A[:,1]*b[1]  
(A*b.reshape(-1)).sum(axis=1)
```

```
array([16, 49, 8, 5])
```

행렬-행렬의 곱셈: 열조합

- 앞 행렬의 열을 조합하여 결과의 열을 계산
- 1열

$$\begin{bmatrix} 2 & 19 & 5 \\ 12 & 2 & 0 \\ 9 & 1 & 9 \\ 4 & 1 & 16 \end{bmatrix} \times \begin{bmatrix} 8 & 16 \\ 17 & 15 \\ 4 & 11 \end{bmatrix}$$



$$8 \begin{bmatrix} 2 \\ 12 \\ 9 \\ 4 \end{bmatrix} + 17 \begin{bmatrix} 19 \\ 2 \\ 1 \\ 1 \end{bmatrix} + 4 \begin{bmatrix} 5 \\ 0 \\ 9 \\ 16 \end{bmatrix}$$

||

||

||

$$\begin{bmatrix} 16 \\ 96 \\ 72 \\ 32 \end{bmatrix} + \begin{bmatrix} 323 \\ 34 \\ 17 \\ 17 \end{bmatrix} + \begin{bmatrix} 20 \\ 0 \\ 36 \\ 64 \end{bmatrix} = \begin{bmatrix} 359 \\ 130 \\ 125 \\ 113 \end{bmatrix}$$

행렬-행렬의 곱셈: 열조합

- 2열

$$\begin{bmatrix} 2 & 19 & 5 \\ 12 & 2 & 0 \\ 9 & 1 & 9 \\ 4 & 1 & 16 \end{bmatrix} \times \begin{bmatrix} 8 & 16 \\ 17 & 15 \\ 4 & 11 \end{bmatrix}$$



$$16 \begin{bmatrix} 2 \\ 12 \\ 9 \\ 4 \end{bmatrix} + 15 \begin{bmatrix} 19 \\ 2 \\ 1 \\ 1 \end{bmatrix} + 11 \begin{bmatrix} 5 \\ 0 \\ 9 \\ 16 \end{bmatrix}$$

||

||

||

$$\begin{bmatrix} 359 \\ 130 \\ 125 \\ 113 \end{bmatrix}$$

$$\begin{bmatrix} 32 \\ 192 \\ 144 \\ 64 \end{bmatrix} + \begin{bmatrix} 285 \\ 30 \\ 15 \\ 15 \end{bmatrix} + \begin{bmatrix} 55 \\ 0 \\ 99 \\ 176 \end{bmatrix} = \begin{bmatrix} 372 \\ 222 \\ 258 \\ 255 \end{bmatrix}$$

행렬-행렬의 곱셈: 행조합

- 뒤 행렬의 행을 조합하여 결과의 행을 계산

$$\begin{bmatrix} 2 & 19 & 5 \\ 12 & 2 & 0 \\ 9 & 1 & 9 \\ 4 & 1 & 16 \end{bmatrix} \times \begin{bmatrix} 8 & 16 \\ 17 & 15 \\ 4 & 11 \end{bmatrix}$$

$$\begin{aligned} [2] \times [8, 16] &= [16, 32] \\ [19] \times [17, 15] &= [323, 285] \\ [5] \times [4, 11] &= [20, 55] \end{aligned} \quad + \quad [359, 372]; \text{ 1행}$$

$$\begin{aligned} [12] \times [8, 16] &= [96, 192] \\ [2] \times [17, 15] &= [34, 30] \\ [0] \times [4, 11] &= [0, 0] \end{aligned} \quad + \quad [130, 222]; \text{ 2행}$$

행렬 연산의 일반 성질

- 곱셈의 교환법칙이 성립하지 않는다.

$$\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}$$

$$(k\mathbf{A})\mathbf{B} = k(\mathbf{AB})$$

$$(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C})$$

$$(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$$

$$\mathbf{A} + \mathbf{0} = \mathbf{A}$$

$$(\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC}$$

$$\mathbf{A} + (-\mathbf{A}) = \mathbf{0}$$

$$\mathbf{C}(\mathbf{A} + \mathbf{B}) = \mathbf{CA} + \mathbf{CB}$$

$$c(\mathbf{A} + \mathbf{B}) = c\mathbf{A} + c\mathbf{B}$$

$$(c + k)\mathbf{A} = c\mathbf{A} + k\mathbf{A}$$

신경망에서 행렬-열우선

- 신경망의 각 레이어는 벡터
- 피드포워드 과정은 벡터에서 벡터로의 선형 변환 : 행렬곱 한번으로

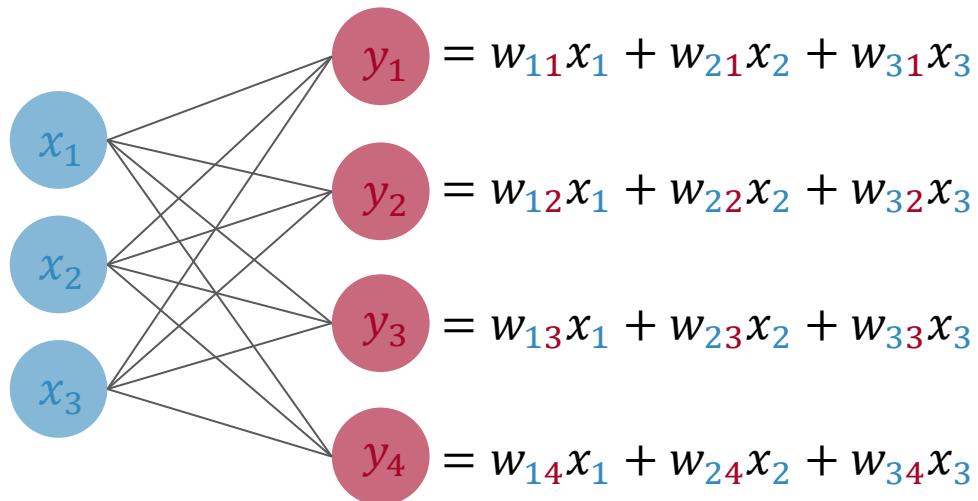
$$\begin{aligned} y_1 &= w_{11}x_1 + w_{12}x_2 + w_{13}x_3 \\ y_2 &= w_{21}x_1 + w_{22}x_2 + w_{23}x_3 \\ y_3 &= w_{31}x_1 + w_{32}x_2 + w_{33}x_3 \\ y_4 &= w_{41}x_1 + w_{42}x_2 + w_{43}x_3 \end{aligned}$$
$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{pmatrix} = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \\ w_{41} & w_{42} & w_{43} \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

y **W** **x**
(4,1) (4,3) (3,1)

$$f_1: \mathbb{R}^3 \rightarrow \mathbb{R}^4$$

신경망에서 행렬-행우선

- 신경망의 각 레이어는 벡터
- 피드포워드 과정은 벡터에서 벡터로의 선형 변환 : 행렬곱 한번으로



$$\begin{bmatrix} y_1 & y_2 & y_3 & y_4 \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \\ w_{31} & w_{32} & w_{33} & w_{34} \end{bmatrix}$$

\mathbf{y}^T \mathbf{x}^T \mathbf{W}

(1,4) (1,3) (3,4)

$$f_1: \mathbb{R}^3 \rightarrow \mathbb{R}^4$$

행렬-벡터 연산

- Python 구현 두 가지 방식
 - For loop 방식 : 직관적이면서 구현이 쉬움
 - 벡터화vectorization 연산 : 덜 직관적이지만 효율적
- ipynb 파일로 몇 가지 예제를 실습

행렬 벡터 곱셈 표기

- 행렬과 벡터 곱셈 $\mathbf{c} = \mathbf{Ab}$

인덱스 표기

$$c_i = \sum_j A_{ij} b_j$$

아인슈타인 서메이션 컨벤션 Einstein summation convention

$$c_i = A_{ij} b_j$$

$$\left[\begin{array}{c} j \\ \hline \downarrow \\ \mathbf{A} \end{array} \right] \times \left[\begin{array}{c} \mathbf{b} \\ \downarrow \\ j \end{array} \right] = \left[\begin{array}{c} \mathbf{c} \\ \downarrow \\ i \end{array} \right]$$

행렬 벡터 곱셈 표기

- 행렬과 벡터 곱셈 $\mathbf{C} = \mathbf{AB}$

인덱스 표기

$$c_{ik} = \sum_j A_{ij} B_{jk}$$

The diagram illustrates the Einstein summation convention for matrix-vector multiplication. It shows three matrices: A (blue), B (red), and C (green). Matrix A is a row vector with index j (red) and dimension k (green). Matrix B is a column vector with index j (red) and dimension k (green). The product AB results in matrix C, which is a column vector with index i (blue) and dimension k (green). The indices j and k are summed over, indicated by the double vertical arrows between A and B.

$$\begin{bmatrix} & j \\ & \longrightarrow \\ & A \end{bmatrix} \times \begin{bmatrix} & k \\ & \longrightarrow \\ & B \end{bmatrix} = \begin{bmatrix} & k \\ & \longrightarrow \\ & C \end{bmatrix}$$

아인슈타인 서메이션 컨벤션 Einstein summation convention

$$c_{ik} = A_{ij} B_{jk}$$

행렬-벡터 연산 예(1)

- 주어진 식

$$y_i = \sum_{j=1}^m A_{ij}x_j$$

- For loop 방식

```
y = []
temp = 0
for i in range(A.shape[0]) :
    for j in range(A.shape[1]) :
        temp += A[i,j]*x[j]
    y.append(temp)
    temp = 0
```

vectorization

$$\mathbf{y} = \mathbf{A}\mathbf{x}$$

$$\mathbf{y} = \mathbf{A}.\text{dot}(\mathbf{x})$$

행렬-벡터 연산 예(1)

- 주어진 식

$$y_i = \sum_{j=1}^m A_{ji}x_j$$

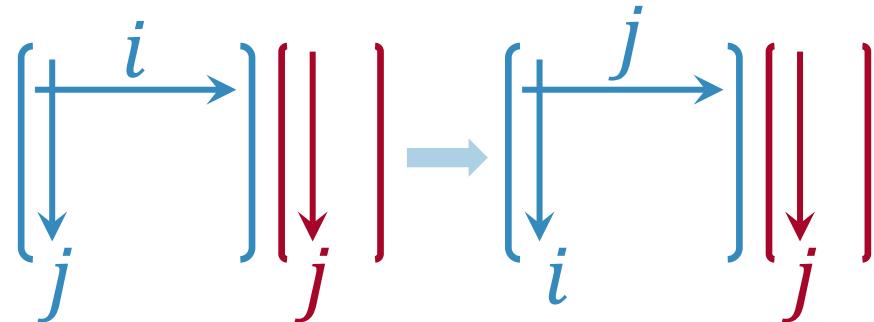
- For loop 방식

```
y = []
temp = 0
for i in range(A.shape[0]) :
    for j in range(A.shape[1]) :
        temp += A[j,i]*x[j]
    y.append(temp)
    temp = 0
```

vectorization

$$\mathbf{y} = \mathbf{A}^T \mathbf{x}$$

$$\mathbf{y} = \mathbf{A.T}.dot(\mathbf{x})$$



행렬-벡터 연산 예(2)

- 주어진 식

$$\mathbf{s} = \sum_{i=1}^m \mathbf{x}^{(i)} (\mathbf{x}^{(i)})^T$$

$$\mathbf{x}^{(1)} = [1 \quad 2 \quad 3]^T$$

$$\mathbf{x}^{(2)} = [4 \quad 5 \quad 6]^T$$

$$\mathbf{x}^{(3)} = [7 \quad 8 \quad 9]^T$$

$$\mathbf{x}^{(4)} = [10 \quad 11 \quad 12]^T$$

$$\mathbf{x}^{(5)} = [13 \quad 14 \quad 15]^T$$

$$\begin{aligned}\mathbf{x}^{(1)} (\mathbf{x}^{(1)})^T & \qquad \mathbf{x}^{(2)} (\mathbf{x}^{(2)})^T & \mathbf{x}^{(3)} (\mathbf{x}^{(4)})^T \\ \mathbf{s} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 3 & 6 & 9 \end{bmatrix} + \begin{bmatrix} 16 & 20 & 24 \\ 20 & 25 & 30 \\ 24 & 30 & 36 \end{bmatrix} + \begin{bmatrix} 49 & 56 & 63 \\ 56 & 64 & 72 \\ 63 & 72 & 81 \end{bmatrix} \\ & + \begin{bmatrix} 100 & 110 & 120 \\ 110 & 121 & 132 \\ 120 & 132 & 144 \end{bmatrix} + \begin{bmatrix} 169 & 182 & 195 \\ 182 & 196 & 210 \\ 195 & 210 & 225 \end{bmatrix} \\ & \qquad \qquad \qquad \mathbf{x}^{(4)} (\mathbf{x}^{(4)})^T & \qquad \qquad \qquad \mathbf{x}^{(5)} (\mathbf{x}^{(5)})^T\end{aligned}$$

행렬-벡터 연산 for loop

- 주어진 식

$$\mathbf{S} = \sum_{i=1}^m \mathbf{x}^{(i)} (\mathbf{x}^{(i)})^T$$

```
X = [x1, x2, x3, x4, x5]
m = len(X)
S = np.zeros((x1.shape[0], x1.shape[0])), dtype=int)
```

```
for i in range(m):
    x_i = X[i]
    S += np.dot(x_i, x_i.T)
```

행렬-벡터 연산 vectorization

- 주어진 식

$$\mathbf{S} = \sum_{i=1}^m \mathbf{x}^{(i)} (\mathbf{x}^{(i)})^T$$

$$\mathbf{X}^T = \begin{bmatrix} \mathbf{x}^{(1)} & \mathbf{x}^{(2)} & \mathbf{x}^{(3)} & \mathbf{x}^{(4)} & \mathbf{x}^{(5)} \end{bmatrix} \times \begin{bmatrix} \mathbf{x}^{(1)} = [1 & 2 & 3] \\ \mathbf{x}^{(2)} = [4 & 5 & 6] \\ \mathbf{x}^{(3)} = [7 & 8 & 9] \\ \mathbf{x}^{(4)} = [10 & 11 & 12] \\ \mathbf{x}^{(5)} = [13 & 14 & 15] \end{bmatrix} = \mathbf{X}$$

$(3 \times 5) \qquad \qquad \qquad (5 \times 3)$

```
X = np.array([x1, x2, x3, x4, x5]).reshape(5,3)      # row major
S = np.dot(X.T, X)
```