

머신 러닝 · 딥러닝에 필요한 수학 기초 with 파이썬

Linear Regression
선형 회귀

조준우
metamath@gmail.com

학습 개요

- 선형회귀
 - 목적함수의 정의
 - 다항 기저함수
 - 목적함수의 미분
 - 경사 하강법 적용
 - 정규방정식
- 머신러닝 일반 이슈
 - 과적합과 레귤러라이제이션
- 다변수 선형회귀
- 주요 참고 문헌
 - Pattern Recognition and Machine Learning, Christopher Bishop, Springer


학습데이터 생성

- Sin 함수 + 적당한 노이즈



- $N=10$
 $x_{\text{train}} = \text{np.linspace}(0, 1, N)$
 $t_{\text{train}} =$
 $\text{np.sin}(2*\text{np.pi}*x_{\text{train}}) +$
 $(\text{np.random.randn}(N)/5)$
- $N_{\text{test}}=100$
 $x_{\text{test}} = \text{np.linspace}(0, 1,$
 $N_{\text{test}})$
 $t_{\text{test}} =$
 $\text{np.sin}(2*\text{np.pi}*x_{\text{test}}) +$
 $(\text{np.random.randn}(N_{\text{test}})/5)$


학습데이터와 모델



● 빨간 점만 보고



곡선을 찾고 싶다.



휘지 않는 막대를 쓸까?



휘어지는 철사를 쓸까?

MODEL

선형 모델 Linear Model

- 주어진 데이터를 직선으로 표현

$$y(x, \mathbf{w}) = w_0 + w_1 x$$

- 입력 x 는 스칼라(숫자 하나) 결정해야 하는 파라미터 2개 w_0, w_1

$$y(x, \mathbf{w}) = w_0 \times 1 + w_1 \times x$$

- 벡터 형식


$$y(\mathbf{x}, \mathbf{w}) = w_0 \times 1 + w_1 \times x = (w_0 \quad w_1) \cdot \begin{pmatrix} 1 \\ x \end{pmatrix} = \mathbf{w}^T \mathbf{x}$$

선형 모델

- $w_0 = 1, w_1 = -2$ 라면 $\mathbf{w}^T \mathbf{x}$ 는 아래와 같다.


- 여기서 $\mathbf{x}_n = \begin{pmatrix} 1 \\ x_n \end{pmatrix}$

$$\mathbf{X}\mathbf{w} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_N \end{bmatrix} \times \begin{pmatrix} w_0 \\ w_1 \end{pmatrix} = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{pmatrix}$$



기저함수Basis Functions

- 어떤 함수를 만들어 내기 위한 재료 함수
 - 2차식을 위한 재료 함수 : $1, x, x^2$
 - $3x^2 + 4x + 2 = 3 \times x^2 + 4 \times x + 2 \times 1$



$$f(x) = c_1 x^0 + c_2 x^1 + c_3 \sin(x) + c_4 \exp(x)$$

$$f(x) = c_1 x^0 + c_2 x^1 + c_3 x^3 + c_4 x^4$$

$$f(x) = c_1 \phi_1(x) + c_2 \phi_2(x) + c_3 \phi_3(x) + c_4 \phi_4(x)$$

임의의 함수로 표현

어떤 재료함수들의 조합이 아닐까?

다항식 기저 Polynomial Basis

- 다항식으로 적당한 곡선을 만들자

$$y(x, \mathbf{w}) = w_0x^0 + w_1x^1 + w_2x^2 + \cdots + w_Mx^M = \sum_{j=0}^M w_jx^j$$

- 우리가 가진 데이터의 모양은 $y(x, \mathbf{w})$ 와 같지 않을까? → 가설
- 결정해야 할 것은?
 - 항은 몇 개까지 만들까? $M=?$
 - $M+1$ 개의 w 들은 어떻게 설정할까?

다항 특성 Polynomial Features

- 주어진 데이터 x 이외에 x^0, x^2, x^M 이 추가 되었으므로 특성(feature)이 추가

$$y(x, \mathbf{w}) = w_0x^0 + w_1x^1 + w_2x^2 + \cdots + w_Mx^M = \sum_{j=0}^M w_jx^j$$

- 주어진 데이터가 주택 가격 관련 데이터라면.....
 - x : 주택의 너비, x^2 : 주택의 면적, x^3 : 주택 외관 전체의 부피 → 대상의 특성
 - t : 주택 가격

기저함수의 벡터 표현

- 아래 가설 $y(x, \mathbf{w})$ 을 벡터형식으로 표현

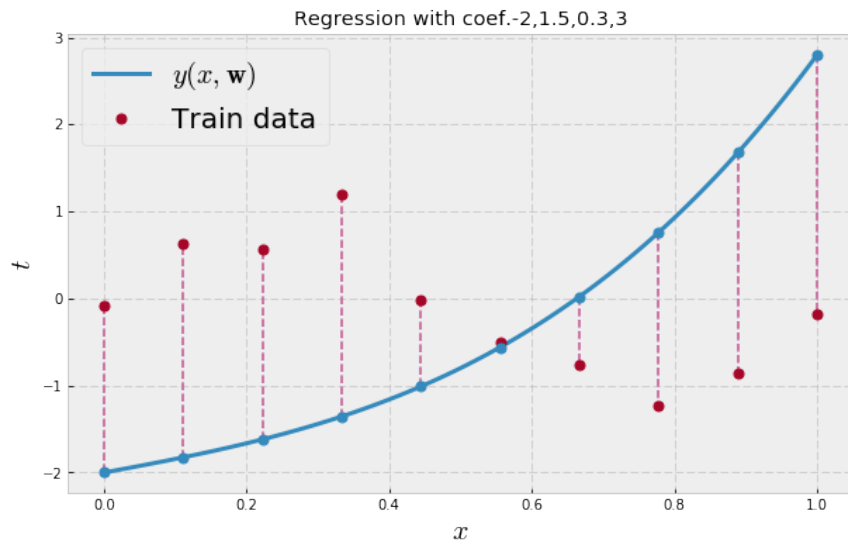
$$y(x, \mathbf{w}) = w_0 x^0 + w_1 x^1 + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^M w_j x^j$$

$$y(x, \mathbf{w}) = [w_0 \quad w_1 \quad w_2 \quad \cdots \quad w_M] \begin{bmatrix} x^0 \\ x^1 \\ x^2 \\ \vdots \\ x^M \end{bmatrix} = \mathbf{w}^T \boldsymbol{\phi}(x) \quad \boldsymbol{\phi}(x): \mathbb{R} \rightarrow \mathbb{R}^{M+1}$$

그냥 맘대로 적당히...

- 그냥 맘대로 적당히...
- $M = 3, w_0 = -2, w_1 = 1.5, w_2 = 0.3, w_3 = 3$

$$y(x, \mathbf{w}) = -2 + 1.5x^1 + 0.3x^2 + 3x^3$$



numpy vs sklearn

- numpy, sklearn을 이용한 선형회귀
- 두 패키지에서 모두 회귀 알고리즘 제공

1차 다항식

```
z_lin = np.polyfit(x_train, t_train, 1)
```

M차 다항식

```
z_nonlin = np.polyfit(x_train, t_train,  
M)
```



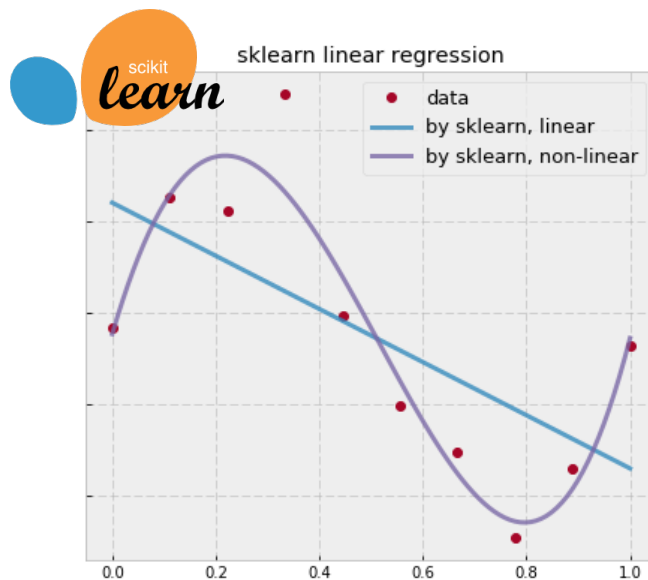
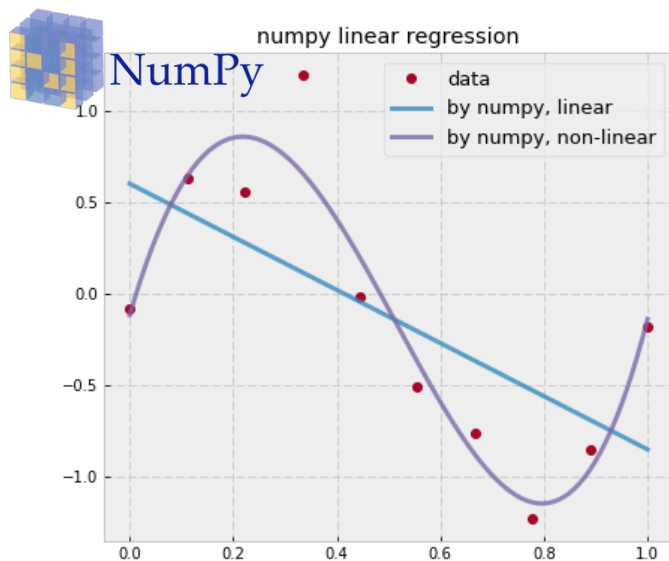
```
model =  
LinearRegression(fit_intercept=True)  
model.fit(x_train[:, np.newaxis],  
t_train)
```

```
poly_model =  
make_pipeline(PolynomialFeatures(M),  
LinearRegression())  
poly_model.fit(x_train[:, np.newaxis],  
t_train)
```



numpy vs sklearn

- numpy coef. : [3.2748 14.1305 -27.1019 9.6745], Bias:-0.1181
- sklearn coef. : [3.2748 14.1305 -27.1019 9.6745], Bias:-0.1181



직접 만들자!

- 이제 배운 지식을 무기로 numpy, sklearn에서 제공하는 알고리즘을 직접 만들어보자!
 - 경사하강법
 - 정규방정식 풀기
- 관련된 일반 이슈
 - 레귤러라이제이션 : L1, L2

경사하강을 이용한 선형회귀

- 목적 : 정의된 에러함수를 최소화
- 결과 : 에러를 최소로 하는 w
- 도구 : 4주차에 만든 minimize 함수
- 추가사항
 - 과적합의 의미
 - 과적합을 방지하기 위한 규제항 추가

얼마나 못했나? measure P

- Error 함수, 로스함수, 코스트함수 : 목적함수

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 \quad (1.1) \quad E(\mathbf{w}) = \frac{1}{2N} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 \quad (1.1 *)$$


- \mathbf{w} : 결정해야 하는 회귀계수(벡터 변수)
 - x_n : 데이터의 입력 값(일반적으로 벡터 변수, 여기서는 스칼라)
 - t_n : 데이터의 타겟 값(여기서는 y 좌표값)
- 오차의 제곱을 최소화시키기를 원함 → 최소제곱법 least square

에러함수 Error Function

- 에러 함수

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

$$E(\mathbf{w}) = \frac{1}{2N} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$



에러값 계산

- 에러 함수

$$y = -2 + 1.5 * x_{\text{train}} + 0.3 * x_{\text{train}}^2 + 3 * x_{\text{train}}^3$$

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

```
print(0.5 * (((y - t_train) ** 2).sum()))
```

결과 : 20.917214052454877


- 이 값이 가능한 작아지기를 원한다.

가설과 에러 함수

데이터

가설(다항함수형태)

에러함수(목적함수)




$$y(x, \mathbf{w}) = \mathbf{w}^T \boldsymbol{\phi}(x)$$


$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

가설과 에러 함수

데이터



가설(신경망 형태)



$$= y(x, \mathbf{w})$$

에러함수(목적함수)

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

에러함수 코드 Error Function Code

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

```
def E(w, M, x, t):  
    """  
    E(w) = (1/2) * sum_{n=1}^{N} {y(x_n, w) - t_n}^2  
    y(x_n, w) = w_0*x^0 + w_1*x^1 + w_2*x^2 + ... + w_M*x^M  
    """  
    X = np.array([ x**i for i in range(M+1) ])  
    y = (w.reshape(-1,1) * X).sum(axis=0)  
  
    return 0.5*(( y - t)**2 ).sum())
```

에러함수의 경사도 벡터

- 수치 미분 함수를 사용 $\frac{\partial E(\mathbf{w})}{\partial \mathbf{w}} = \left(\sum_{n=1}^N (\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n) - t_n) \right) \boldsymbol{\phi}(\mathbf{x}_n)^T$
- 또는 직접 미분
$$= \mathbf{w}^T \left(\sum_{n=1}^N \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^T \right) - \sum_{n=1}^N t_n \boldsymbol{\phi}(\mathbf{x}_n)^T$$
$$= \mathbf{w}^T (\boldsymbol{\Phi}^T \boldsymbol{\Phi}) - \mathbf{t}^T \boldsymbol{\Phi}$$

```
def grad_anal(w, M, x, t):
```

```
    """
```

This function computes the analytic gradient of the objective function
x, t : data for error function eval.

```
    """
```

```
    N = x.shape[0]
```

```
    PI = np.hstack( (np.power(x.reshape(N,1), p) for p in range(M+1)) )
```

```
    g = np.dot(w.T, np.dot(PI.T, PI) ) - np.dot(t.T, PI)
```

```
    return g.astype('longdouble')
```



auto_diff_test.ipynb

경사하강 실험 코드

- 정의된 에러함수(목적함수)와 목적함수의 경사도벡터 함수를 이용하여 경사하강 시도

```
# M을 0, 1, 3, 9에 대해서 한번씩 피팅  
ms = [0, 1, 3, 8]
```

```
# 피팅결과 구해진 파라미터를 W에 저장  
W = []
```

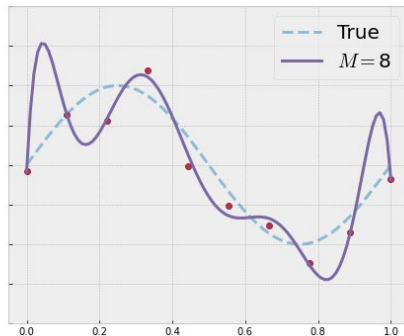
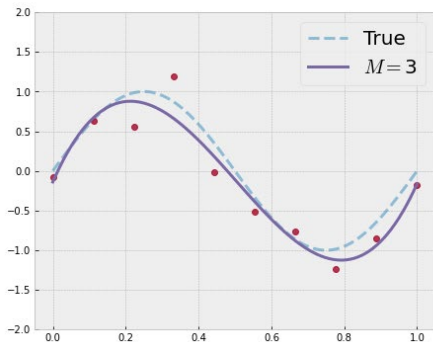
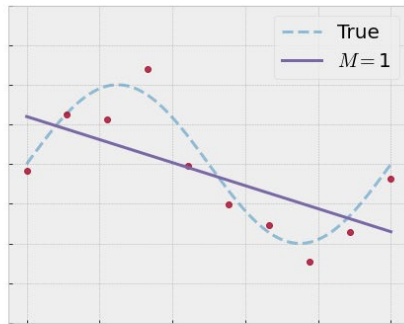
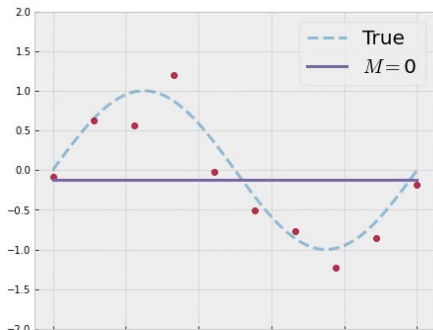
```
# 학습데이터를 넘기면서 fitting
```

```
for M in ms :  
    x0 = np.random.uniform(-1, 1, M+1)  
    W.append(minimize(E, x0, args=(M, x_train, t_train),  
                      jac=grad_anal, method="CGFR", verbose_step=500))
```



lin_reg.ipynb

경사하강 실험 결과



	M=0	M=1	M=3	M=8
0	-0.12627	0.599645	-0.139682	-0.082299
1	NaN	-1.451831	10.483091	90.751711
2	NaN	NaN	-31.185369	-1698.272058
3	NaN	NaN	20.680189	12647.995512
4	NaN	NaN	NaN	-47354.721824
5	NaN	NaN	NaN	97608.618543
6	NaN	NaN	NaN	-112611.383684
7	NaN	NaN	NaN	68191.475090
8	NaN	NaN	NaN	-16874.563844

에러 평가

- RMS(Root Mean Square)

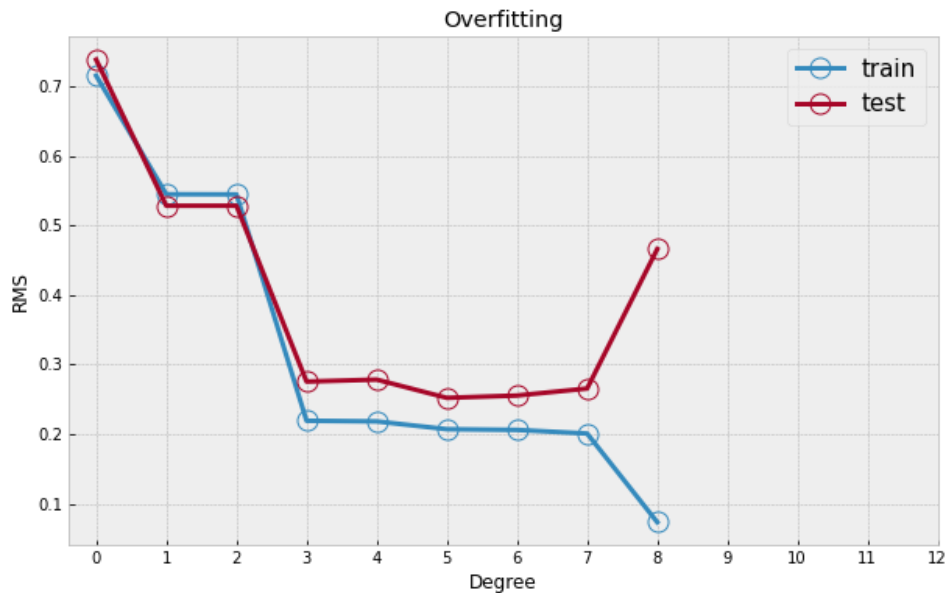
$$E_{RMS} = \sqrt{\frac{2E(\mathbf{w}^*)}{N}}$$

```
def rms(w, E, M, x, t) :  
    return np.sqrt( (2*E(w, M, x, t))  
                    / x.shape[0] )
```

- 루트 : 오차 함수값의 제곱을 상쇄
- N 으로 나누어 평균적인 오차를 구함
- 2 곱하기는 오차함수에 (1/2) 때문
- 1차에서 8차까지 회귀 결과에 대해 학습, 테스트 데이터로 각각 RMS를 계산

과적합(오버피팅Overfitting)

- 학습데이터에 대한 에러는 감소
- 테스트데이터에 대한 에러는 증가
- 해결
 - 더 많은 데이터
 - 레귤러라이제이션Regularization



과적합 해결 (1)

- 더 많은 데이터를 모아서.....



과적합 해결 (2)


- 레귤러라이제이션 Regularization
 - 일반화, 규제화, 정규화
 - 목적함수에 **페널티 항**을 더해서

$$\tilde{E} = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

\tilde{E} 가 커진다. \mathbf{w} 가 커지면

과적합 해결 (2)

- L2 레귤러라이제이션
- $W: [-0.0818 \quad 7.7064 \quad -14.9829 \quad -6.3789 \quad 5.8483 \quad 9.1046 \quad 5.3738 \quad -0.6798 \quad -6.0898]$



제약최소화와 규제화[†]

- 페널티 항의 일반적 모양

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$$

||

- 제약최소화 문제

Minimize $\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2$

$$s. t. \sum_{j=1}^M |w_j|^q \leq \eta$$

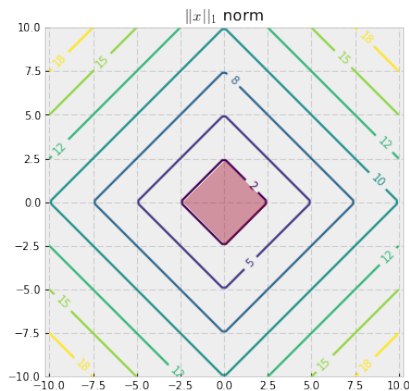
제약최소화와 규제화

- 규제항에 따라 w 가
등고선 영역 안에 갇힘(제약)

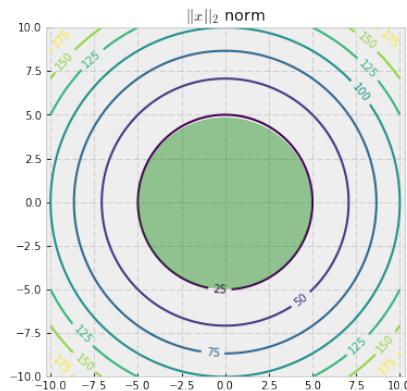
$$s.t. \sum_{j=1}^M |w_j|^q \leq \eta$$

$$q = 1, \eta = 2$$


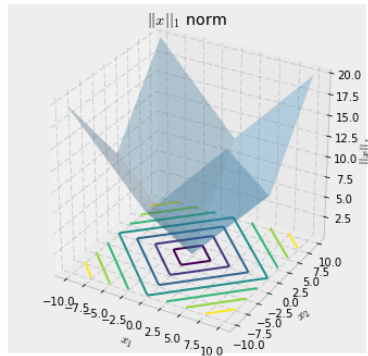
$$q = 2, \eta = 25$$



L1



L2





제약최소화와 규제화

- λ 증가, η 감소: 레귤러라이제이션 효과 커짐

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$$

Minimize $\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2$

s. t. $\sum_{j=1}^M |w_j|^q \leq \eta$



레귤러라이제이션 실험

- 에러함수 수정 $\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$

```
def E(w, M, x, t):
```

```
.....
```

```
if regularizer == 'L2' :
```

```
    # L2 reg
```

```
    if not reg_intercept :
```

```
        return 0.5*(( (y - t)**2 ).sum()) + (lamda/2.)*np.linalg.norm(w[1:])**2
```

```
    else :
```

```
        return 0.5*(( (y - t)**2 ).sum()) + (lamda/2.)*np.linalg.norm(w)**2
```

```
elif regularizer == 'L1' :
```

```
    # L1 reg.
```

```
    if not reg_intercept :
```

```
        return 0.5*(( (y - t)**2 ).sum()) + (lamda/2.)*(np.abs(w[1:]).sum())
```

```
    else :
```

```
        return 0.5*(( (y - t)**2 ).sum()) + (lamda/2.)*(np.abs(w).sum())
```


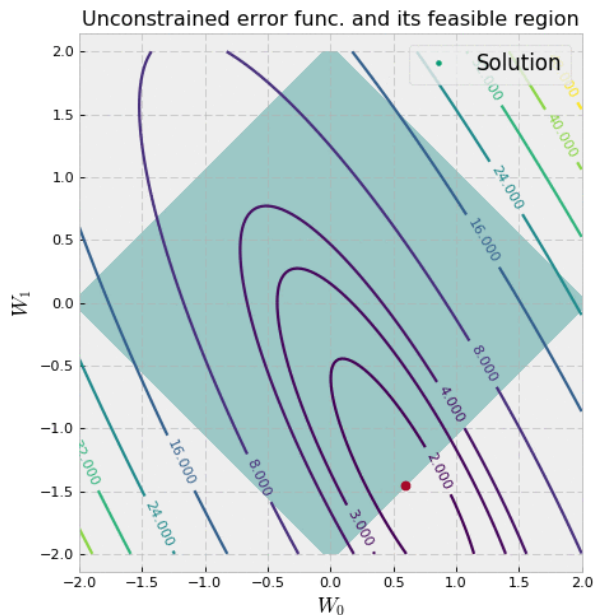
```
else :
```

```
    return 0.5*(( (y - t)**2 ).sum())
```

w_0 를 규제항에 포함 할지 말지 결정

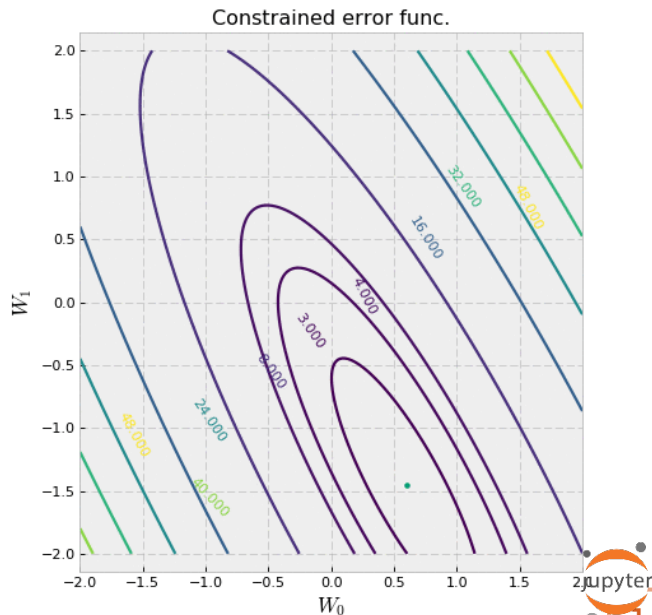
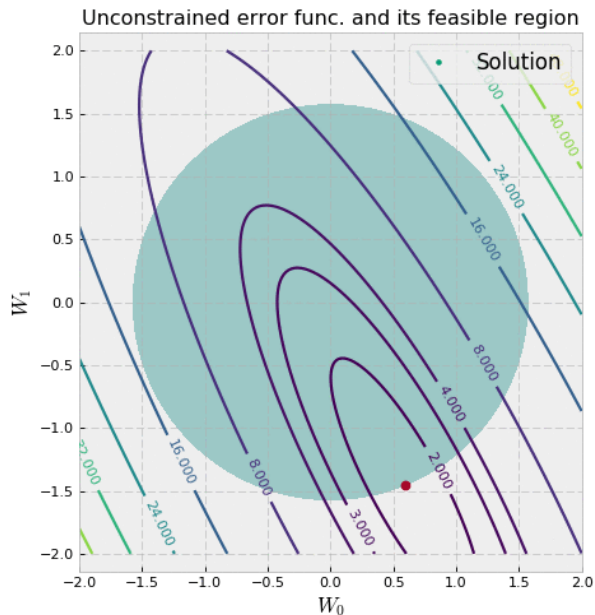
L1 Regularization

- $0 \leq \lambda \leq 3$



L2 Regularization

- $0 \leq \lambda \leq 15$



정규방정식을 이용한 선형회귀

- 목적 : 주어진 목적함수를 만족시키는 \mathbf{w} 를 한번에 찾는다.
- 결과 : 에러를 최소로 하는 \mathbf{w}
- 도구 : 미분
- 추가사항⁺
 - 최소제곱의 기하학적 의미
 - L2 규제가 적용된 경우 정규방정식 해

가설의 표현

- $y(\mathbf{x}_n, \mathbf{w}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)$: D차원 벡터에 대한 기저함수 형식
 - \mathbf{x}_n : D차원 벡터인 입력 데이터
 - $\boldsymbol{\phi}(\mathbf{x}_n) : \mathbb{R}^D \rightarrow \mathbb{R}^M$ 인 다변수 벡터함수, $\phi_j(\mathbf{x})$: 다변수 실함수
 - M : 기저함수의 개수
 - $\mathbf{w} = (w_0 \ \cdots \ w_{M-1})^T$, $\boldsymbol{\phi}(\mathbf{x}) = (\phi_0(\mathbf{x}) \ \cdots \ \phi_{M-1}(\mathbf{x}))^T$
 - $D = 1$ 이고 다항 기저인 경우

$$\boldsymbol{\phi}(x) = \left\{ \begin{array}{l} \phi_0(x) \equiv x^0 \\ \phi_1(x) \equiv x^1 \\ \vdots \\ \phi_{M-1}(x) \equiv x^{M-1} \end{array} \right\}$$

- $y(\mathbf{x}_n, \mathbf{w}) = \mathbf{w}^T \mathbf{x}_n$: D차원 벡터를 그대로 사용
 - $\mathbf{w} = (w_0 \ \cdots \ w_{D-1})^T$, $\mathbf{x} = (x_0 \ \cdots \ x_{D-1})^T$

목적함수

- 기저함수를 쓰는 경우

- $E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2$
- N : 데이터의 개수
- \mathbf{w} 의 차원 : 기저함수의 개수 M

$$[w_0 \quad w_1 \quad \cdots \quad w_{M-1}] \begin{bmatrix} x_n^0 \\ x_n^1 \\ \vdots \\ x_n^{M-1} \end{bmatrix}$$

- 입력변수에 대해 선형인 경우

- $E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \mathbf{x}_n\}^2$
- N : 데이터의 개수
- \mathbf{w} 의 차원 : 입력변수와 동일한 D

$$[w_0 \quad w_1] \begin{bmatrix} 1 \\ x \end{bmatrix}$$

스칼라를 벡터로 미분

- 분모 레이아웃

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial x_i a_i}{\partial x_1} \\ \frac{\partial x_i a_i}{\partial x_2} \\ \vdots \\ \frac{\partial x_i a_i}{\partial x_n} \end{bmatrix} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix} = \mathbf{a}$$

- 분자 레이아웃

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \left[\frac{\partial x_i a_i}{\partial x_1} \quad \frac{\partial x_i a_i}{\partial x_2} \quad \dots \quad \frac{\partial x_i a_i}{\partial x_n} \right] = [a_1 \quad a_2 \quad \dots \quad a_n] = \mathbf{a}^T$$

목적함수의 미분

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2$$

$$\begin{aligned} \frac{\partial E_D(\mathbf{w})}{\partial \mathbf{w}} &= \frac{\partial}{\partial \mathbf{w}} \left\{ \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\}^2 \right\} \quad \boxed{\phantom{\frac{\partial}{\partial \mathbf{w}}}} + \boxed{\phantom{\frac{\partial}{\partial \mathbf{w}}}} + \dots + \boxed{\phantom{\frac{\partial}{\partial \mathbf{w}}}} \\ &= \frac{1}{2} \sum_{n=1}^N 2\{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\} \left(\frac{\partial}{\partial \mathbf{w}} \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\} \right) \\ &= \sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\} (-\boldsymbol{\phi}(\mathbf{x}_n)^T) = - \boxed{\sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\} \boldsymbol{\phi}(\mathbf{x}_n)^T} = 0 \end{aligned}$$

목적함수의 미분

$$\sum_{n=1}^N \{t_n - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n)\} \boldsymbol{\phi}(\mathbf{x}_n)^T = 0$$

$$\sum_{n=1}^N \{t_n \boldsymbol{\phi}(\mathbf{x}_n)^T - \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^T\} = 0$$

$$\sum_{n=1}^N t_n \boldsymbol{\phi}(\mathbf{x}_n)^T - \mathbf{w}^T \left(\sum_{n=1}^N \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^T \right) = 0$$

$$\mathbf{w}^T \left(\sum_{n=1}^N \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^T \right) = \sum_{n=1}^N t_n \boldsymbol{\phi}(\mathbf{x}_n)^T$$

정규방정식

$$\mathbf{w}^T \left(\sum_{n=1}^N \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^T \right) = \sum_{n=1}^N t_n \boldsymbol{\phi}(\mathbf{x}_n)^T$$

$$\mathbf{w}^T (\boldsymbol{\Phi}^T \boldsymbol{\Phi}) = \mathbf{t}^T \boldsymbol{\Phi}$$

$$\{\mathbf{w}^T (\boldsymbol{\Phi}^T \boldsymbol{\Phi})\}^T = \{\mathbf{t}^T \boldsymbol{\Phi}\}^T$$

$$(\boldsymbol{\Phi}^T \boldsymbol{\Phi}) \mathbf{w} = \boldsymbol{\Phi}^T \mathbf{t}$$

$$\mathbf{w} = (\boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \mathbf{t}$$

Moore-Penrose
Pseudo Inverse


$$\begin{array}{c} \boldsymbol{\Phi} \\ \left[\begin{array}{cccc} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{array} \right] \end{array} \begin{array}{c} \mathbf{w} \\ \left[\begin{array}{c} w_0 \\ w_1 \\ \vdots \\ w_{M-1} \end{array} \right] \end{array} \stackrel{?}{=} \begin{array}{c} \mathbf{t} \\ \left[\begin{array}{c} t_1 \\ t_2 \\ \vdots \\ t_N \end{array} \right] \end{array}$$

Design Matrix

$$\mathbf{w} = \boldsymbol{\Phi}^{-1} \mathbf{t}$$

열(col.)들의 선형조합으로 \mathbf{t} 를 만들 수 없다.

최소제곱의 기하학적 의미



정규방정식 실험

- Step 1. 주어진 데이터 $\mathcal{D} = (\mathbf{t}, \mathbf{X})$, $\mathbf{t} = (t_1, t_2, \dots, t_N)^T$, $\mathbf{X} = (\mathbf{x}_1^T, \mathbf{x}_2^T, \dots, \mathbf{x}_N^T)^T$
- Step 2. 필요하다면 기저함수를 M 개 선택한다.
- Step 3. 디자인 행렬을 구성한다.

$$\Phi = \begin{bmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix}$$

- Step 4. 정규방정식을 푼다.

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{t}$$

정규방정식 실험 코드

- 디자인 행렬 구성

$$\mathbf{X} = \begin{bmatrix} 0. & 1. \\ 0.1111 & 1. \\ 0.2222 & 1. \\ 0.3333 & 1. \\ 0.4444 & 1. \\ 0.5556 & 1. \\ 0.6667 & 1. \\ 0.7778 & 1. \\ 0.8889 & 1. \\ 1. & 1. \end{bmatrix}$$

$$\Phi = \begin{matrix} & x^0 & x^1 & x^2 & x^3 \\ \begin{bmatrix} 1. & 0. & 0. & 0. \\ 1. & 0.1111 & 0.0123 & 0.0014 \\ 1. & 0.2222 & 0.0494 & 0.011 \\ 1. & 0.3333 & 0.1111 & 0.037 \\ 1. & 0.4444 & 0.1975 & 0.0878 \\ 1. & 0.5556 & 0.3086 & 0.1715 \\ 1. & 0.6667 & 0.4444 & 0.2963 \\ 1. & 0.7778 & 0.6049 & 0.4705 \\ 1. & 0.8889 & 0.7901 & 0.7023 \\ 1. & 1. & 1. & 1. \end{bmatrix} \end{matrix}$$

```
X = np.append( x_train.reshape(-1, 1), np.ones(N).reshape(-1,1), axis=1 )
```

```
PI = np.hstack( (np.power(x_train.reshape(-1,1), p) for p in range(M)) )
```

정규방정식 실험 코드

- 정규방정식 풀이



normal_eq.ipynb

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{t}$$

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

```
w_lin = np.dot( inv(np.dot(X.T, X)) ,  
                np.dot(X.T , t_train.reshape(N,1)) ).reshape(-1)
```

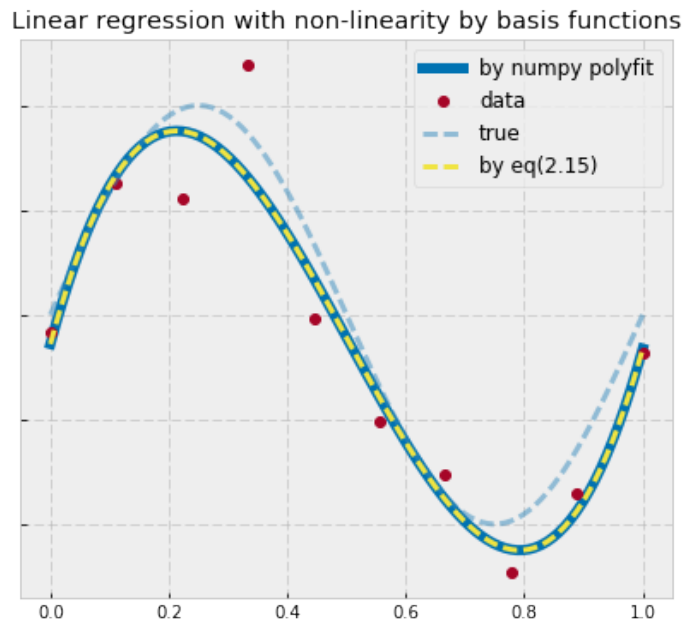
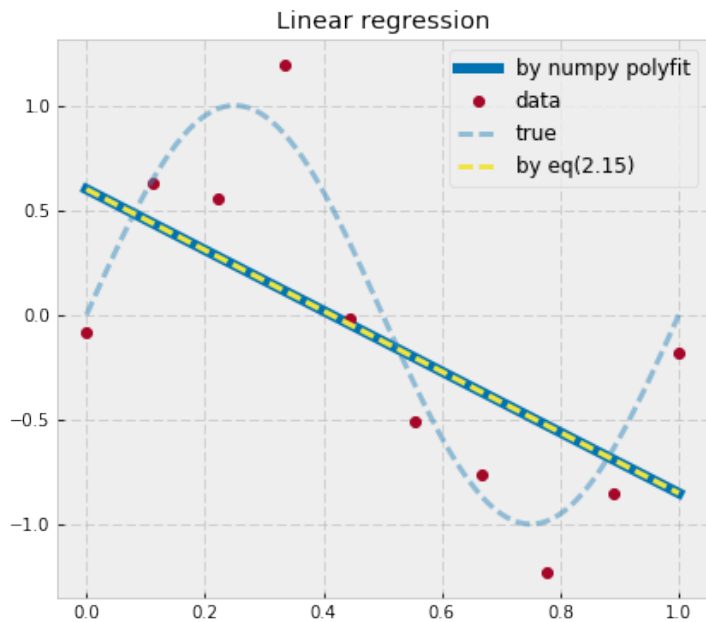
```
w_lin = np.linalg.solve(np.dot(X.T, X),  
                        np.dot(X.T, t_train.reshape(N,1)) ).reshape(-1)
```

```
w_nonlin = np.dot( inv(np.dot(PI.T, PI)) ,  
                   np.dot(PI.T, t_train.reshape(N,1)) ).reshape(-1)[::-1]
```

```
w_nonlin = np.linalg.solve(np.dot(PI.T, PI),  
                           np.dot(PI.T, t_train.reshape(N,1)) ).reshape(-1)[::-1]
```

정규방정식 실험 결과

- numpy polyfit 함수와 결과 비교




정규방정식의 규제항

- L2 레귤러라이제이션을 적용한 정규방정식

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{t}$$

$$\mathbf{w} = (\Phi^T \Phi + \lambda \mathbf{I}_M)^{-1} \Phi^T \mathbf{t}$$



다변수 선형회귀

- 입력변수의 차원만 증가 $D = 1 \rightarrow D = 2, 3, 4, \dots$ 데이터 \rightarrow 특성

$$\Phi = \begin{bmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{bmatrix}$$

특성0 특성1 특성M-1

다변수 스칼라 함수

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix} = \begin{bmatrix} 1 & x_1^{(1)} & \cdots & x_D^{(1)} \\ 1 & x_1^{(2)} & \cdots & x_D^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(N)} & \cdots & x_D^{(N)} \end{bmatrix}$$

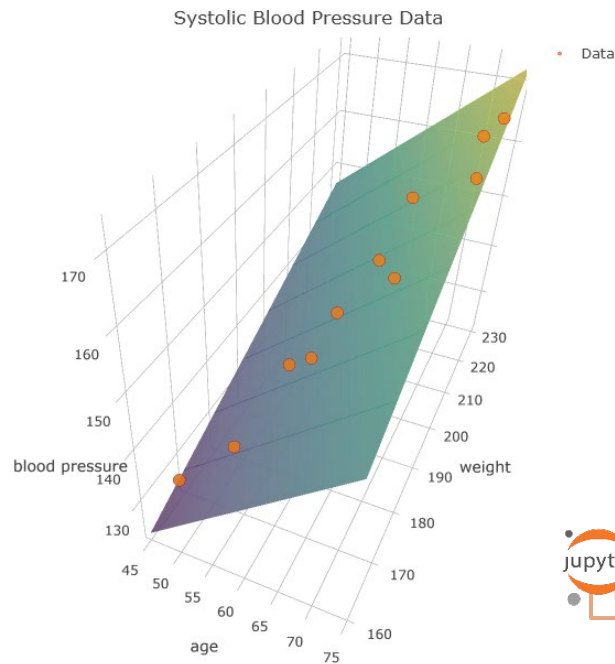

특성0 키 몸무게

$\mathbf{x}_1 \xrightarrow{\text{숫자 D개인 벡터가 들어가서}} \phi_j(\) \xrightarrow{\text{1번 데이터에 대한 j번째 특징 출력}} f_j^{(1)}$



$x_j^{(i)}$ i번 데이터에 대한 j번째 특징

다변수 선형회귀

- 입력변수의 차원만 증가 $D = 2, \mathbf{X} = (11, 3)$



선형회귀의 선형성



JS

metamath1.github.io/noviceml/linearity.html